

Projet RI

Off the Beaten Path: Let's Replace Term-Based Retrieval with k-NN Search

L. Boytsov, D. Novak, Y. Malkov, E. Nyberg, Oct. 2016

The three potatoes :

Chu Amélie

Tambellini Alan

Thomas Élise

Mai 2026

Table des Matières

①

État de l'art

②

Description
du papier

③

Forces et
faiblesses de
la contribution

④

Implémentation
et résultats

⑤

Protocole d'
évaluation

⑥

Conclusion

Pipeline classique de l'époque

1. Index inversé avec BM25 (rapide mais rate des documents)
2. Sélection de 1000 candidats
3. Reranking avec IBM Model 1 (lourd)

Pipeline du papier

1. Indexation kNN approximative avec BM25 + IBM Model 1 (direct et rapide)
2. Sélection des meilleurs candidats (sans rater ceux qui ont des problèmes de synonymie)

Pipeline SOTA

1. Index inversé avec BM25
2. Index k-NN approximatif avec des embeddings (Transformers)
3. Fusion et normalisation

Introduction du kNN face aux index inversés classiques (Lucene/BM25)

→ Résolution du problème du ***vocabulary mismatch***

Évaluation pour trois modèles de similarité

- Lexicaux classiques : **BM25** et **Cosine TF-IDF**
- Traduction statistique : **BM25 + IBM Model 1**
- Sémantique dense : **Cosine Embed**

Évaluation des performances des index de plus proches voisins approximatifs (ANN)

- Approche par graphes : **SW-graph**
 - Approche par pivots : **NAPP**
- Comparaison à la recherche exacte : **Brute Force**

***Vocabulary
Mismatch***

User's query


"car"

Document

"automobile"

2

Pipeline Retrieval



Datasets

Extraction des QA des collections suivantes :

- *Yahoo! Answers Manner version 2.0*
- *Yahoo! Answers Comprehensive version 1.0*
- *Stack Overflow*

Collection name	QA pairs					Terms in question	Terms in answer
	total	train	dev1/dev2	test	tran		
<i>Manner</i>	142K	86K	7K/21K	29K	4.2M	13.9	40.6
<i>Comprehensive</i>	4.4M	212K	11K/42K	10K	4.1M	17.8	34.1
<i>Stack Overflow</i>	6.2M	298K	15K/58K	10K	5.8M	48.4	33.1

Cosine Embed


Similarité cosinus
entre des embeddings
pré-entraînés

Préservation de la
morphologie (sans
lemmatisation)

Cosine TF-IDF


Similarité cosinus
entre les vecteurs
TF-IDF

Texte lemmatisé

**BM25**


Évolution de TF-IDF
prenant en compte la
saturation de la
fréquence et la
longueur des
documents

Texte lemmatisé

**BM25 + IBM
Model 1**

Combinaison linéaire :
score lexical (BM25) +
score probabiliste (IBM)

Pont sémantique :
calcule la probabilité de
correspondance entre
les mots de la question
et de la réponse



2

Index textuel

Focus : contenu et sémantique brute des mots

Lucene

Terme (Stemmed) Liste d'affectations (Doc ID, positions)

enseign → (Doc 2, [pos1])

étudi → (Doc 4, [pos1, pos2]),
(Doc 6, [pos2])

Forward index

Doc ID Doc/Terme

1 → Chat

2 → Chien

Index inversé

Doc/Terme Doc ID

Chat → 1 3

Chien → 2 5

2

Index de similarité


Focus : géométrie et proximité des objets

Algorithmes de recherche des k plus proches voisins approximatifs (ANN)

NAPP

Neighborhood APProximation index


Ensemble des données



Signature d'un point x : calcul des pivots les plus proches de x

SW-graph

Small World Graph
Technique incarnée par **HNSW**
(Hierarchical Navigable Small World)



Rappel

Mesure la capacité du système à trouver tous les documents pertinents présents dans la base de données pour une requête donnée

À maximiser - valeurs [0, 1]

$$\text{Rappel} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{|D_{\text{trouvés}}(q_i) \cap D_{\text{pertinents}}(q_i)|}{|D_{\text{pertinents}}(q_i)|}$$

Q : ensemble des query

Précision au rang 1

1 si le tout premier document retourné est pertinent
0 sinon

À maximiser - valeurs [0, 1]

$$P@1 = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \text{Rel}(q_i, 1)$$

Rel :

- 1 si le 1er doc retourné est pertinent
- 0 sinon

Rang réciproque moyen (MRR)

Évalue la position (le rang) du premier document pertinent trouvé

À maximiser - valeurs [0, 1]

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rang}_i}$$

rang : position du 1er doc pertinent retourné

3

Forces et faiblesses de la contribution

Forces

- Première tentative réussie d'**application d'un kNN** à une fonction de similarité combinant BM25 et IBM Model 1
- Résolution du problème du ***vocabulary mismatch***
- Perte de précision d'un kNN approximatif minime (~10%)
- Gains de vitesse kNN approximatif (1 à 2 ordres de grandeur)

Faiblesses

- **Fléau de la dimensionnalité** du kNN
- Peu adaptable à grande échelle
- Biais de l'approximation du kNN
- Généralisation de l'approche limitée (QA)

4

Implémentation et résultats

Datasets

Collection name	QA pairs					Terms in question	Terms in answer
	total	train	dev1/dev2	test	tran		
<i>Manner</i>	142K	86K	7K/21K	29K	4.2M	13.9	40.6
<i>Comprehensive</i>	4.4M	212K	11K/42K	10K	4.1M	17.8	34.1
<i>Stack Overflow</i>	6.2M	298K	15K/58K	10K	5.8M	48.4	33.1



<i>Stack Overflow (available)</i>	6.2M	298K	15K/58K	73K	5.8M	48.5	33.2
-----------------------------------	------	------	---------	-----	------	------	------

4

Implémentation et résultats

Datasets

Collection name	QA pairs				tran	Terms in question	Terms in answer
	total	train	dev1/dev2	test			
<i>Manner</i>	142K	86K	7K/21K	29K	4.2M	13.9	40.6
<i>Comprehensive</i>	4.4M	212K	11K/42K	10K	4.1M	17.8	34.1
<i>Stack Overflow</i>	6.2M	298K	15K/58K	10K	5.8M	48.4	33.1

<i>Stack Overflow (available)</i>	6.2M	298K	15K/58K	73K	5.8M	48.5	33.2
-----------------------------------	------	------	---------	-----	------	------	------

4

Reproductibilité du papier

Facilités


- Lien vers la librairie donnée et branche associée correspondant au papier
- Auteur accessible par contact
 - Directives données sur l'un des modèles du papier (nouvelle branche)

Difficultés


- Ancienneté du papier (2016)
 - Dépendances anciennes, nécessité d'adapter les codes
- Accès à un seul dataset
- L'auteur n'a pas pu nous fournir les datasets manquantes

Rappel des modèles sur le dataset stackoverflow

Résultats de l'article



Nos résultats



4

Améliorations

Utilisation des embeddings



Leo (Leonid) Boytsov  (He/Him) • 3:29 PM

But again, a good question is why anyone would be interested in non-neural approaches in 2026 😊

Utilisation des embeddings:

Modèle : BF cosine embed


statique

Word2Vec Google News Corpus (2013)



all-MiniLM-L6-v2 (BERT distilled) (2021)


contextuelle




4

Améliorations

Précision au rang 1 des modèles sur Stackoverflow



MRR des modèles sur Stackoverflow



Évaluation humaine de la requête et des documents récupérés sur **2 modèles**

- BF BM25 + IBM Model 1
- BF cosine embed

Dataset: Natural Questions

Mode d'évaluation: Note de 1 à 5

Nombre de requêtes à évaluer: 20 questions identiques pour 3 personnes

!! Seulement les questions où les modèles se trompent.

what are the first 3 cards in poker called

Doc1

World Series of Poker The winner of each event receives a World Series of Poker bracelet and a monetary prize based on the number of entrants and buy-in amounts. Over the years, the tournament has grown in both the number of events and in the number of participants. Each year, the WSOP culminates with the \$10,000 no-limit hold'em "Main Event," which, since 2004, has attracted entrants numbering in the thousands. The victor receives a multi-million dollar cash prize and a bracelet, which has become the most coveted award a poker player can win.[3] The winner of the World Series of Poker Main Event is considered to be the World Champion of Poker.[4]

Note Doc1

1

Doc2

Betting in poker Until the first bet is made each player in turn may "check," which is to not place a bet, or "open," which is to make the first bet. After the first bet each player may "fold," which is to drop out of the hand losing any bets they have already made; "call," which is to match the highest bet so far made; or "raise," which is to increase the previous high bet.

Note Doc2

1



Passer à la question suivante

5

Résultats d'évaluation

	BF BM25 + IBM Model 1	BF cosine embed
Metric		
Moyenne	1.72	2.90
Médiane	1.0	3.0
Std	1.14	1.43
% score ≥ 4	10.0%	35.0%

	Moy. BM25+IBM1	Moy. Cosine	Delta (BM25-Cosine)	BM25 wins %	Cosine wins %	Ties %
Utilisateur						
User 1	1.25	2.50	-1.25	10.0%	50.0%	40.0%
User 2	1.85	3.05	-1.20	15.0%	55.0%	30.0%
User 3	2.05	3.15	-1.10	10.0%	65.0%	25.0%



- Précurseur de la recherche dense k-NN approximative
- Partiellement reproductible
- Amélioration avec embeddings

